



## 第十九章：手写 VIO 课程大作业 作业思路提示

主讲人 Horizon



## 1、更优的优化策略

(a) 选择更优的 LM 阻尼因子策略，使得 VINS-Mono 在 MH-05 数据集上收敛速度更快或者精度更高；

(b) 实现 Dog-Leg 算法替代 LM 算法，并测试替换后的 VINS-Mono 在 MH-05 上算法精度；

详细的实验报告包括：对迭代时间和精度的评估。其中，精度评估可以采用 evo 工具，github，地址为：<https://github.com/MichaelGrupp/evo>。

## 2、更快的 MakeHessian 矩阵

采用任何一种或多种加速方式（多线程、SSE指令集等）对信息矩阵的拼接函数加速，给出详细的实验对比报告。

# 更优的优化策略

---

## 1、更优的优化策略

- (a) 更优的 LM 阻尼因子更新策略；
- (b) 实现 Dog-Leg 算法替代 LM 算法；
- (c) 限制最大迭代步数；
- (d) 设置残差改变量阈值；
- (e) 设置优化参数增量阈值。

# 阻尼因子更新策略

1.  $\lambda_0 = \lambda_o$ ;  $\lambda_o$  is user-specified [8].  
 use eq'n (13) for  $\mathbf{h}_{lm}$  and eq'n (16) for  $\rho$   
 if  $\rho_i(\mathbf{h}) > \epsilon_4$ :  $\mathbf{p} \leftarrow \mathbf{p} + \mathbf{h}$ ;  $\lambda_{i+1} = \max[\lambda_i/L_{\downarrow}, 10^{-7}]$ ;  
 otherwise:  $\lambda_{i+1} = \min[\lambda_i L_{\uparrow}, 10^7]$ ;
2.  $\lambda_0 = \lambda_o \max[\text{diag}[\mathbf{J}^T \mathbf{W} \mathbf{J}]]$ ;  $\lambda_o$  is user-specified.  
 use eq'n (12) for  $\mathbf{h}_{lm}$  and eq'n (15) for  $\rho$   

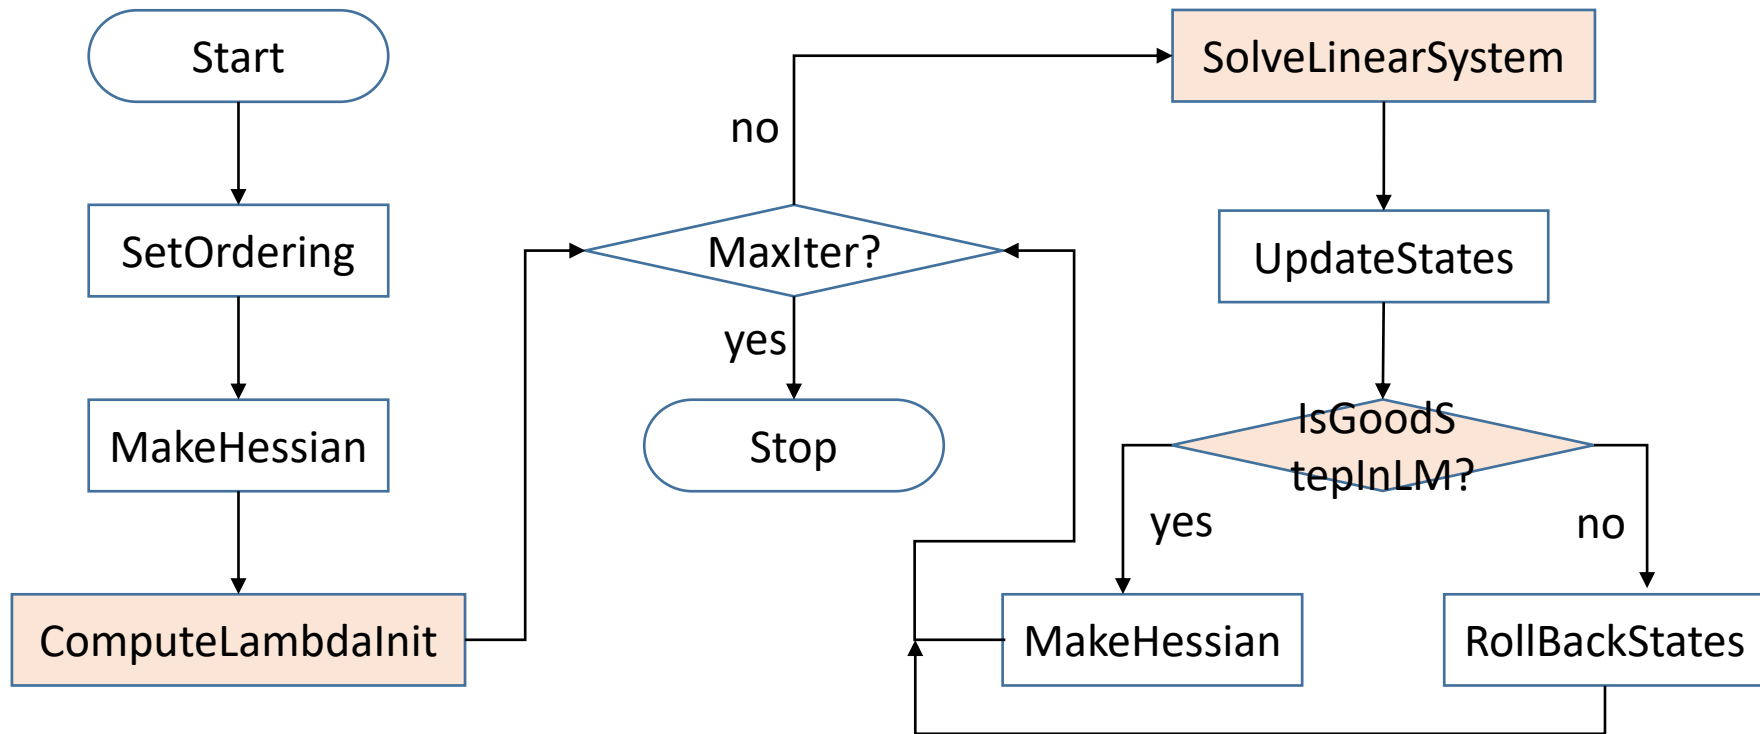
$$\alpha = \left( \left( \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})) \right)^T \mathbf{h} \right) / \left( (\chi^2(\mathbf{p} + \mathbf{h}) - \chi^2(\mathbf{p})) / 2 + 2 \left( \mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})) \right)^T \mathbf{h} \right)$$
;  
 if  $\rho_i(\alpha \mathbf{h}) > \epsilon_4$ :  $\mathbf{p} \leftarrow \mathbf{p} + \alpha \mathbf{h}$ ;  $\lambda_{i+1} = \max[\lambda_i / (1 + \alpha), 10^{-7}]$ ;  
 otherwise:  $\lambda_{i+1} = \lambda_i + |\chi^2(\mathbf{p} + \alpha \mathbf{h}) - \chi^2(\mathbf{p})| / (2\alpha)$ ;
3.  $\lambda_0 = \lambda_o \max[\text{diag}[\mathbf{J}^T \mathbf{W} \mathbf{J}]]$ ;  $\lambda_o$  is user-specified [9].  
 use eq'n (12) for  $\mathbf{h}_{lm}$  and eq'n (15) for  $\rho$   
 if  $\rho_i(\mathbf{h}) > \epsilon_4$ :  $\mathbf{p} \leftarrow \mathbf{p} + \mathbf{h}$ ;  $\lambda_{i+1} = \lambda_i \max[1/3, 1 - (2\rho_i - 1)^3]$ ;  $\nu_i = 2$ ;  
 otherwise:  $\lambda_{i+1} = \lambda_i \nu_i$ ;  $\nu_{i+1} = 2\nu_i$ ;

# 阻尼因子更新策略

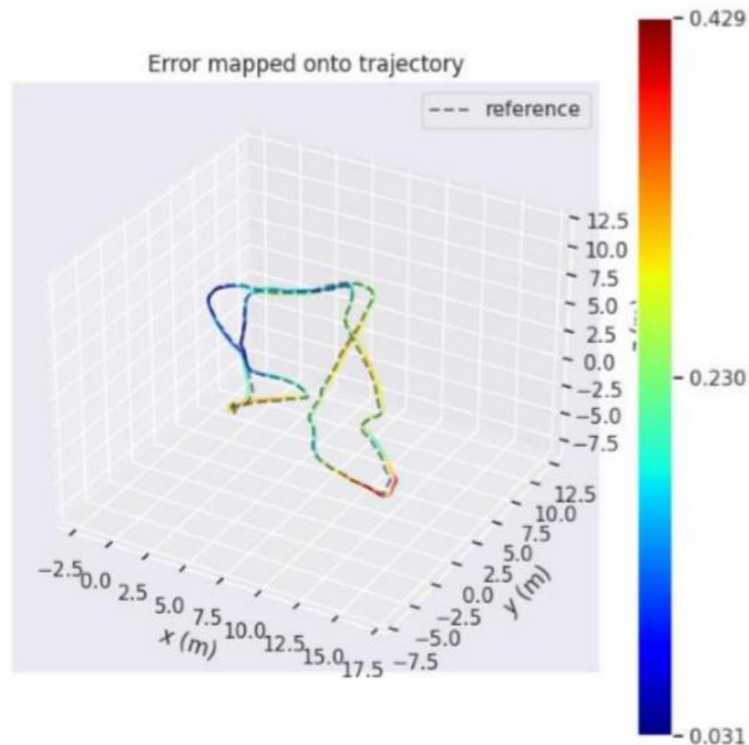
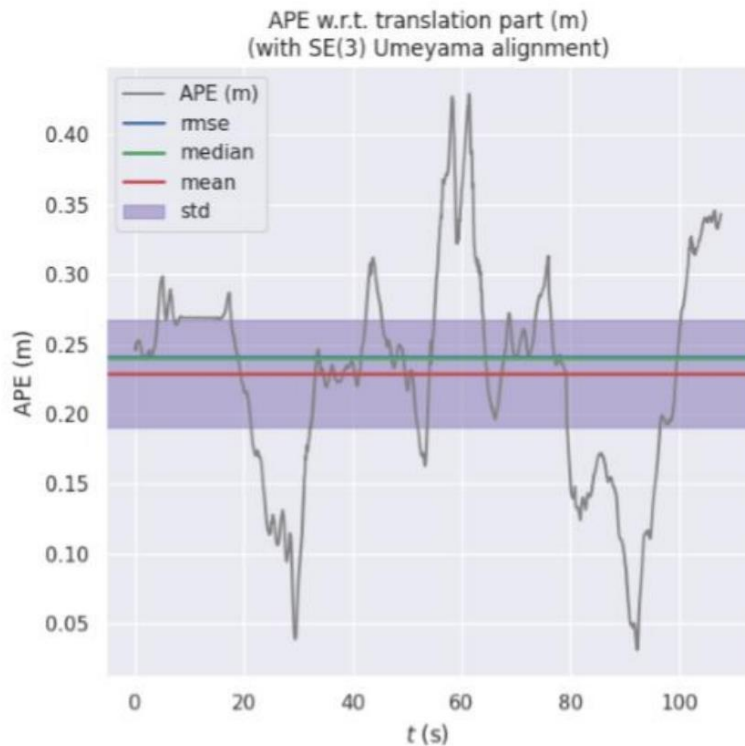
## 三种 LM 阻尼因子更新策略对比：

方法	初始化	求解方程	$\lambda$ 变化比例
1	与 Hessian 矩阵无关	Hessian 对角线元素加上 $\lambda$ * Hessian 对角线元素	固定
2	与 Hessian 矩阵有关	Hessian 对角线加上 $\lambda$	与 $\alpha$ 有关
3	与 Hessian 矩阵有关	Hessian 对角线加上 $\lambda$	与 $\rho$ 有关

# 阻尼因子更新策略



# 阻尼因子更新策略



# Dog-Leg 算法

- 属于信赖域 (Trust Region) 类优化算法;
- Dog-Leg 算法在以当前点为中心, 半径为  $\Delta$  的区域 (信赖域) 内, 将目标函数做了二阶近似;
- Dog-Leg 算法分别计算了最速下降法和高斯牛顿法的最优增量  $\delta_{sd}$  和  $\delta_{gn}$ , 并根据信赖域的大小来选择合适的增量。

【参考文献】Lourakis M, Argyros A A . Is Levenberg-Marquardt the Most Efficient Optimization Algorithm for Implementing Bundle Adjustment?[C] // 10th IEEE International Conference on Computer Vision (ICCV 2005), 17-20 October 2005, Beijing, China. IEEE, 2005.



# Dog-Leg 算法步骤

- 第一步：计算最速下降法和高斯牛顿法的最优增量  $\delta_{sd}$  和  $\delta_{gn}$

## ■ $\delta_{sd}$

- $F(x + \Delta x) = \frac{1}{2} \|f(x + \Delta x)\|_2^2 \approx F(x) + J^\top f \Delta x + \frac{1}{2} \Delta x^\top J^\top J \Delta x, s. t. \|\Delta x\| \leq \Delta$
- 增量方向:  $d = F'(x) = (J^\top f)^\top$
- 增量步长:  $\frac{\partial F(x - \alpha d)}{\partial \alpha} = 0 \quad \alpha = \frac{(J^\top f)^\top J^\top f}{(J^\top f)^\top (J^\top J) J^\top f}$
- $\delta_{sd} \quad \delta_{sd} = \frac{-(J^\top f)^\top J^\top f}{(J^\top f)^\top (J^\top J) J^\top f} (J^\top f)^\top$  对应代码  $\frac{b^\top b}{b^\top H b} b$

# Dog-Leg 算法步骤


- 第一步：计算最速下降法和高斯牛顿法的最优增量  $\delta_{sd}$  和  $\delta_{gn}$

## ■ $\delta_{gn}$


- $F(x + \Delta x) = \frac{1}{2} \|f(x + \Delta x)\|_2^2 \approx F(x) + J^T f \Delta x + \frac{1}{2} \Delta x^T J^T J \Delta x, s. t. \|\Delta x\| \leq \Delta$
- $J^T J \delta_{gn} = -J^T f$  对应代码  $Hx = b$

# Dog-Leg 算法步骤


- 第二步：计算 Dog-Leg 算法的最优增量  $\delta_{dl}$



$$\text{若 } \|\delta_{gn}\| \leq \Delta, \|\delta_{sd}\| \in \mathbb{R} \\ \delta_{dl} = \delta_{gn}$$



$$\text{若 } \|\delta_{gn}\| > \Delta, \|\delta_{sd}\| > \Delta \\ \delta_{dl} = \frac{\delta_{sd}}{\|\delta_{sd}\|} \Delta$$



$$\text{若 } \|\delta_{gn}\| > \Delta, \|\delta_{sd}\| \leq \Delta \\ \delta_{dl} = \delta_{sd} + \alpha(\delta_{gn} - \delta_{sd})$$

# Dog-Leg 算法步骤

- 第三步：更新 Dog-Leg 算法的信赖域半径  $\Delta$

$$\rho = \frac{F(x + \Delta x) - F(x)}{m_k(x + \Delta x) - m_k(x)}$$

若近似效果不好，即  $\rho \leq 0.25$ ，则缩小信赖域  $\Delta = 0.25 * \Delta$

若近似效果较好，即  $\rho \geq 0.75$ ，则增大信赖域  $\Delta = \max\{\Delta, 3\|\delta_{dl}\|\}$

否则信赖域不变

# 更快地构造海森矩阵

## 2、更快的 MakeHessian 矩阵

(a) OpenMP: 最为便捷, 资料较多:

<http://supercomputingblog.com/openmp/openmp-tutorial-the-basics/>

(b) SSE Instruction Set: 英特尔公司有效增强 CPU 浮点运算能力的指令集:

<http://supercomputingblog.com/optimization/getting-started-with-sse-programming/>

(c) Nvidia CUDA: 英伟达 GPU 的加速运算库, 较为复杂:

<https://cuda-tutorial.readthedocs.io/en/latest/tutorials/tutorial01/>



深蓝学院  
shenlanxueyuan.com

感谢各位聆听 !  
Thanks for Listening

